Data Cleaning dan Quality di Skala Besar

Pertemuan 4 — Analisis Big Data

S1 Teknik Informatika / Sistem Informasi | Semester Ganjil 2026

Agenda Pertemuan 4

1. 6 Dimensi Kualitas Data
2. Profiling cepat dengan DuckDB `SUMMARIZE`
3. Menangani missing values dengan Polars
4. Deteksi dan penanganan outlier (IQR + domain knowledge)
5. Standardisasi teks dan validasi email
6. Menangani duplikat
7. Great Expectations: validasi data otomatis
8. Pipeline cleaning yang modular dan reproducible

Milestone 2 Tugas 1 diumumkan hari ini! Target check-in: Pertemuan 5

6 Dimensi Kualitas Data

Dimensi	Pertanyaan Kunci	Contoh Masalah
Completeness	Apakah semua nilai yang seharusnya ada, tersedia?	Kolom rating kosong (null)
Accuracy	Apakah nilai sesuai kondisi nyata?	Harga tercatat negatif
Consistency	Apakah format seragam di seluruh data?	"jakarta", "JAKARTA", " Jakarta "
Timeliness	Apakah data cukup baru untuk dipakai?	Data stok yang sudah usang
Uniqueness	Apakah tidak ada duplikasi yang tidak disengaja?	Baris transaksi tercatat dua kali
Validity	Apakah nilai sesuai aturan/domain yang disepakati?	Email tanpa simbol `@`

> Sebelum membersihkan data, tentukan dulu dimensi mana yang paling bermasalah — strategi cleaning berbeda untuk tiap dimensi.

Profiling Cepat dengan DuckDB `SUMMARIZE`

Satu perintah untuk mendapatkan ringkasan statistik seluruh kolom: tipe data, null%, min/max, distinct count, dan lainnya.

```
import duckdb

con = duckdb.connect()
con.register("transaksi", df_kotor)  # DataFrame Polars langsung di-query

profil = con.execute("SUMMARIZE SELECT * FROM transaksi").df()
print(profil)
```

```
# Laporan kualitas data kustom dengan SQL
con.execute("""
    SELECT
        COUNT(*) AS total_baris,
        COUNT(*) - COUNT(DISTINCT id_transaksi) AS duplikat,
        SUM(CASE WHEN harga <= 0 THEN 1 ELSE 0 END) AS harga_invalid
    FROM transaksi
""").df()
```

Kuis Checkpoint 1 (Menit 25)

Buka Wayground — Instructor-Paced Mode

3 soal konseptual Data Quality:

1. Dimensi data quality manakah yang mengukur sejauh mana data yang tersedia mencakup seluruh nilai yang seharusnya tercatat?
2. Apa keuntungan utama melakukan profiling data di awal proses analisis pada dataset berukuran besar?
3. Library Great Expectations dalam data pipeline terutama digunakan untuk...

Waktu: 3 menit

Menangani Missing Values

Strategi bergantung pada persentase missing, jenis data, dan dampaknya pada analisis.

```
df_cleaned = df_kotor.with_columns([
    # Numerik: isi dengan median
    pl.col("kuantitas").fill_null(pl.col("kuantitas").median()),

    # Numerik kontekstual: isi dengan mean per grup
    pl.col("rating").fill_null(
        pl.col("rating").mean().over("kategori")
    ).round(1),

    # Kategorik: isi dengan nilai default/modus
    pl.col("status").fill_null("proses"),
])
```

> Hati-hati: mengisi dengan mean/median bisa menyesatkan jika distribusi data sangat miring atau terdapat outlier ekstrem.

Deteksi dan Penanganan Outlier

Metode IQR (Interquartile Range)

```
q1 = df["harga"].quantile(0.25)
q3 = df["harga"].quantile(0.75)
iqr = q3 - q1

batas_bawah = q1 - 1.5 * iqr
batas_atas = q3 + 1.5 * iqr
```

Kombinasikan dengan Domain Knowledge

```
# Batas bisnis: harga wajar Rp1.000 – Rp50.000.000
df.with_columns(
    pl.col("harga")
    .clip(lower_bound=1_000, upper_bound=50_000_000)
    .alias("harga_clean")
)
```

> IQR murni bisa salah mengira transaksi besar yang valid sebagai outlier. Gabungkan dengan pengetahuan bisnis sebelum memutuskan hapus atau clip (windsorization).

Kuis Checkpoint 2 (Menit 55)

Buka Wayground — Instructor-Paced Mode

3 soal teknik cleaning dan validation rules:

4. Dalam penanganan missing values, kapan imputasi dengan nilai rata-rata (mean) berisiko tinggi menyesatkan analisis?
5. Untuk memperoleh ringkasan statistik dari seluruh kolom dalam dataset e-commerce menggunakan DuckDB, perintah SQL yang tepat adalah...
6. Di Polars, metode yang paling tepat untuk menghapus baris duplikat berdasarkan kolom tertentu adalah...

Waktu: 3 menit

Standardisasi Teks dan Validasi Email

```
df_std = df.with_columns([
    # Hapus spasi ekstra, seragamkan Title Case
    pl.col("kota").str.strip_chars().str.to_titlecase(),
    pl.col("kategori").str.strip_chars().str.to_titlecase(),
    pl.col("status").str.strip_chars().str.to_lowercase(),

    # Validasi format email dengan regex
    pl.col("email_pembeli")
    .str.contains(r"^[a-zA-Z0-9._%+\-]+@[a-zA-Z0-9.\-]+\.[a-zA-Z]{2,}$")
    .alias("email_valid"),
])

# Email tidak valid diubah menjadi null (anonim), bukan dihapus barisnya
df_std = df_std.with_columns(
    pl.when(pl.col("email_valid")).then(pl.col("email_pembeli")).otherwise(None)
    .alias("email_pembeli")
)
```

Menangani Duplikat

```
total_baris = len(df)
baris_unik = df.n_unique()
print(f"Duplikat: {total_baris - baris_unik:,}")

# Hapus duplikat berdasarkan kunci, pertahankan kemunculan pertama
df_dedup = df.unique(
    subset=["id_transaksi"],
    keep="first",
    maintain_order=True,
)
```

> Deduplikasi harus berdasarkan **kolom kunci bisnis** (misalnya `id_transaksi`), bukan seluruh baris — dua transaksi berbeda bisa saja punya nilai kolom lain yang kebetulan sama.

Great Expectations: Validasi Data Otomatis

Mendefinisikan aturan kualitas data secara deklaratif agar bisa dicek otomatis di pipeline produksi.

```
import great_expectations as gx

ctx = gx.get_context(mode="ephemeral")
suite = ctx.suites.add(gx.ExpectationSuite(name="aturan_transaksi"))

suite.add_expectation(
    gx.expectations.ExpectColumnValuesToBeBetween(
        column="harga_clean", min_value=1_000, max_value=50_000_000
    )
)
suite.add_expectation(
    gx.expectations.ExpectColumnValuesToBeUnique(column="id_transaksi")
)
suite.add_expectation(
    gx.expectations.ExpectColumnValuesToNotBeNull(column="id_transaksi")
)
```

> Jika `great_expectations` tidak terpasang, aturan yang sama dapat ditulis manual dengan `CASE WHEN` di DuckDB sebagai alternatif.

Pipeline Cleaning yang Modular

Gabungkan seluruh langkah menjadi satu fungsi yang terdokumentasi dan dapat direproduksi.

```
def pipeline_data_cleaning(df_input: pl.DataFrame) -> pl.DataFrame:
    return (
        df_input
        .unique(subset=["id_transaksi"], keep="first", maintain_order=True)
        .filter(pl.col("harga").is_not_null() & (pl.col("harga") > 0))
        .with_columns([
            pl.col("kuantitas").fill_null(pl.col("kuantitas").median()),
            pl.col("rating").fill_null(pl.col("rating").mean().over("kategori")).round(1),
            pl.col("status").fill_null("proses"),
        ])
        .with_columns([
            pl.col("kota").str.strip_chars().str.to_titlecase(),
            pl.col("harga").clip(lower_bound=1_000, upper_bound=50_000_000),
        ])
    )

df_bersih = pipeline_data_cleaning(df_kotor)
```

Kuis Checkpoint 3 (Menit 85)

Buka Wayground — Instructor-Paced Mode

4 soal kasus data anomali:

7. Anda menemukan bahwa kolom umur berisi nilai -5 dan 250 pada dataset BPS. Langkah awal yang paling tepat adalah...
8. Mengapa validasi tipe data (schema validation) sangat krusial saat membaca data CSV berukuran besar di Polars?
9. Strategi penanganan missing value pada data transaksi e-commerce yang paling aman jika nilai yang hilang terjadi pada kolom tanggal transaksi adalah...
10. Penerapan aturan validasi Great Expectations `expect_column_values_to_be_between(column="harga", min_value=0)` bertujuan untuk...

Waktu: 4 menit

Ringkasan Pertemuan 4

Hari ini kita telah mempelajari:

- **6 Dimensi Kualitas Data**: Completeness, Accuracy, Consistency, Timeliness, Uniqueness, Validity
- **Profiling cepat** dengan DuckDB `SUMMARIZE` untuk gambaran menyeluruh dalam satu perintah
- **Missing values**: hapus, isi median/mean/modus, atau isi berdasarkan konteks grup
- **Outlier**: metode IQR dikombinasikan dengan domain knowledge dan windsorization
- **Standardisasi teks** dan validasi format (regex email)
- **Deduplikasi** dan **Great Expectations** untuk validasi otomatis

Milestone 2 Tugas 1: Data Quality dan Profiling — DuckDB `SUMMARIZE` + transformasi Polars.
Target Check-in: Pertemuan 5.

Pertemuan Berikutnya: Exploratory Data Analysis (EDA) dan Visualisasi Interaktif.

Referensi

- Polars User Guide — Missing Data: https://docs.pola.rs/user-guide/expressions/missing-data/
- DuckDB `SUMMARIZE`: https://duckdb.org/docs/sql/statements/summarize.html
- Great Expectations Documentation: https://docs.greatexpectations.io/