Exploratory Data Analysis (EDA) dan Visualisasi Interaktif

Pertemuan 5 — Analisis Big Data

S1 Teknik Informatika / Sistem Informasi | Semester Ganjil 2026

Agenda Pertemuan 5

1. Prinsip EDA pada data berskala besar
2. Pipeline DuckDB (agregasi) → Polars (transform) → Plotly (visualisasi)
3. Grammar of Graphics dengan Altair
4. Distribusi dan deteksi outlier (box plot, histogram)
5. Korelasi antarvariabel (heatmap)
6. Komposisi kategori, tren waktu, dan peta interaktif Indonesia
7. Visualisasi yang menyesatkan dan transformasi data

Check-in Milestone 2 Tugas 1 hari ini!

Prinsip EDA pada Big Data

Masalah Umum

- Membuat notebook lambat atau macet
- Menghasilkan grafik yang padat dan sulit dibaca
- Menyita memori secara tidak perlu

Menggambar jutaan titik data langsung ke browser akan:

Tiga Prinsip Utama

1. **Agregasi dulu** di database (SQL/DuckDB), baru bawa hasil kecil ke visualisasi
2. **Sampling** untuk scatter plot per baris (misal 20.000 dari 1 juta baris)
3. **Profiling ringkas** (`describe()`, cek null) sebelum membuat grafik

> Big data + EDA = kurangi volume data **sebelum** divisualisasikan, bukan sesudahnya.

Pipeline DuckDB → Polars → Plotly

```
import duckdb, polars as pl, plotly.express as px

con = duckdb.connect()
con.register("transaksi", df)  # DataFrame Polars langsung di-query

# 1. Agregasi di DuckDB — hanya hasil kecil yang dibawa ke tahap berikutnya
ringkasan = con.execute("""
    SELECT kota, SUM(harga * kuantitas) AS total_pendapatan
    FROM transaksi
    WHERE status = 'selesai'
    GROUP BY kota
    ORDER BY total_pendapatan DESC
""").pl()

# 2. Visualisasi hasil yang sudah ringkas
px.bar(ringkasan.to_pandas(), x="kota", y="total_pendapatan").show()
```

> Urutan yang efisien: **Query & Agregasi di DuckDB → hasil kecil ke Polars/Pandas → Render Plotly**.

Kuis Checkpoint 1 (Menit 25)

Buka Wayground — Instructor-Paced Mode

3 soal konseptual EDA dan visualisasi:

1. Prinsip utama melakukan EDA pada dataset berukuran besar (big data) sebelum pembuatan grafik adalah...
2. Konsep Grammar of Graphics yang mendasari library seperti Altair menekankan pada...
3. Visualisasi data dapat menjadi menyesatkan (misleading) apabila pembuat grafik...

Waktu: 3 menit

Grammar of Graphics dengan Altair

Altair memetakan kolom data ke elemen visual secara **deklaratif** — bukan menggambar chart manual.

```
import altair as alt

chart = (
    alt.Chart(ringkasan.to_pandas())
    .mark_bar()
    .encode(
        x=alt.X("kota:N", sort="-y"),
        y=alt.Y("total_pendapatan:Q"),
        color=alt.Color("rata_rata_rating:Q"),
        tooltip=["kota", "jumlah_transaksi", "total_pendapatan"],
    )
)
chart
```

Elemen Encoding	Fungsi
`x`, `y`	Posisi data pada sumbu
`color`	Memetakan nilai ke warna
`tooltip`	Info interaktif saat hover

Distribusi dan Deteksi Outlier

Box plot dan histogram jauh lebih informatif dibanding pie chart untuk melihat sebaran dan pencilan.

```
px.box(df_sampel, x="kategori", y="harga", points="outliers",
       title="Distribusi Harga per Kategori")

px.histogram(df_sampel, x="rating", nbins=20,
             title="Distribusi Rating Transaksi")
```

> Heatmap korelasi untuk hubungan linier antarvariabel numerik:

```
px.imshow(df[["harga", "kuantitas", "rating"]].corr(),
          text_auto=".2f", color_continuous_scale="RdBu_r",
          zmin=-1, zmax=1)
```

Kuis Checkpoint 2 (Menit 55)

Buka Wayground — Instructor-Paced Mode

3 soal pemilihan chart dan interaktivitas:

4. Untuk menampilkan distribusi data transaksi numerik dan mendeteksi pencilan secara visual, tipe grafik yang paling tepat adalah...
5. Dalam pipeline analisis DuckDB ke Plotly, urutan langkah yang paling efisien adalah...
6. Untuk menampilkan grafik peta persebaran data kependudukan per provinsi di Indonesia, tipe peta Plotly yang digunakan adalah...

Waktu: 3 menit

Komposisi, Tren, dan Peta Interaktif

Bar Chart vs Pie Chart

Bar chart lebih mudah dibaca untuk banyak kategori — manusia lebih akurat membandingkan panjang batang daripada sudut irisan pie.

```
px.bar(komposisi, x="kategori", y="jumlah")
```

Peta Interaktif (scatter_geo)

```
px.scatter_geo(
    ringkasan_peta,
    lat="lat", lon="lon",
    size="total_pendapatan",
    color="rata_rata_rating",
    hover_name="kota",
    scope="asia",
)
```

Tren Waktu

```
px.line(tren_bulanan, x="bulan", y="total_pendapatan", markers=True)
```

Visualisasi yang Menyesatkan

Memotong sumbu Y (truncated axis) membesar-besarkan perbedaan kecil sehingga menyesatkan interpretasi.

```
# Benar: sumbu Y mulai dari 0
fig = px.bar(data, x="kategori", y="jumlah")
fig.update_yaxes(range=[0, data["jumlah"].max() * 1.1])

# Menyesatkan: sumbu Y dipotong, perbedaan terlihat ekstrem
fig2 = px.bar(data, x="kategori", y="jumlah")
fig2.update_yaxes(range=[data["jumlah"].min() * 0.95, data["jumlah"].max() * 1.01])
```

> Pola melengkung non-linier pada scatter plot? Coba **transformasi logaritma** (`pl.col("harga").log10()`) sebelum menyimpulkan tidak ada hubungan.

Kuis Checkpoint 3 (Menit 85)

Buka Wayground — Instructor-Paced Mode

4 soal interpretasi visualisasi:

7. Jika Anda perlu membuat scatter plot dari dataset berisi 50 juta baris data transaksi, pendekatan terbaik adalah...
8. Manakah pasangan visualisasi dan tujuan analisis yang paling tepat dalam EDA?
9. Keunggulan utama pembuatan grafik interaktif dengan Plotly dibanding grafik statis Matplotlib adalah...
10. Saat menganalisis hubungan antara harga produk dan volume penjualan e-commerce, grafik scatter plot menunjukkan pola melengkung non-linier. Langkah transformasi EDA yang dapat dilakukan adalah...

Waktu: 4 menit

Ringkasan Pertemuan 5

Hari ini kita telah mempelajari:

- **Prinsip EDA big data**: agregasi/sampling dulu, baru visualisasikan
- **Pipeline** DuckDB (agregasi) → Polars (transform) → Plotly/Altair (visualisasi)
- **Grammar of Graphics**: pemetaan deklaratif data ke elemen visual
- **Pemilihan chart**: box plot/histogram (distribusi), heatmap (korelasi), bar chart (komposisi), line chart (tren), scatter geo (peta)
- **Visualisasi menyesatkan** (truncated axis) dan transformasi log untuk pola non-linier

Check-in Milestone 2 Tugas 1: DuckDB `SUMMARIZE` + transformasi Polars untuk cleaning, missing values, outliers, dan validasi dasar.

Pertemuan Berikutnya: Pemrosesan Data Time Series Besar — Resampling, Rolling Windows, `group_by_dynamic()`.

Referensi

- Plotly Express Documentation: https://plotly.com/python/plotly-express/
- Altair Documentation: https://altair-viz.github.io/
- Few, Stephen. *Now You See It: Simple Visualization Techniques for Quantitative Analysis*.