Exploratory Data Analysis (EDA) dan Visualisasi Interaktif

Pertemuan 5 — Analisis Big Data

S1 Teknik Informatika / Sistem Informasi | Semester Ganjil 2026

Agenda Pertemuan 5

1. Motivasi & prinsip EDA pada data berskala besar
2. Pipeline DuckDB (agregasi) → Polars (transform) → Plotly (visualisasi)
3. Grammar of Graphics, sistem tipe data, dan interaktivitas Altair
4. Distribusi dan deteksi outlier (box plot, histogram, heatmap korelasi)
5. Komposisi kategori, tren waktu, dan peta interaktif Indonesia
6. Visualisasi yang menyesatkan dan transformasi data

Check-in Milestone 2 Tugas 1 hari ini!

Mengapa Kita Butuh EDA? (Motivasi)

> *"Exploratory Data Analysis is about looking at data to see what it seems to say."* — **John W. Tukey (1977)**

Sebelum melangkah ke machine learning atau dashboard analitik, analis **wajib** mengeksplorasi data mentah secara interaktif.

Tujuan Strategis EDA:

- **Pahami Distribusi & Struktur:** Mengenali skewness, sebaran nilai, dan batas wajar data.
- **Deteksi Anomali Lebih Awal:** Menemukan outlier ekstrem, nilai null tersembunyi, atau inkonsistensi rekaman.
- **Validasi Asumsi Bisnis:** Membuktikan apakah hipotesis awal sesuai dengan fakta lapangan.

Nilai untuk Analisis Big Data:

- **Mencegah *"Garbage In, Garbage Out"*:** Model canggih tidak berguna jika dilatih dengan data yang cacat.
- **Pemandu Feature Engineering:** Menentukan apakah variabel perlu transformasi (misal: log, clipping).
- **Efisiensi Komputasi:** Mengidentifikasi variabel kunci sebelum menjalankan pemrosesan berat.

> **Prinsip Utama:** EDA bukan sekadar menggambar grafik indah, melainkan proses investigasi mendalam untuk memahami karakteristik sejati dari data.

Mengapa Ringkasan Statistik Saja Menyesatkan?

Mengetahui *mean* dan *standar deviasi* tidak pernah cukup untuk menggambarkan perilaku data yang sebenarnya.

Fenomena Anscombe's Quartet (1973):

- Empat dataset dengan nilai statistik **identik**:
  - Rata-rata $X = 9.0$, Rata-rata $Y = 7.5$
  - Varians $X = 11.0$, Varians $Y = 4.125$
  - Koefisien korelasi $r = 0.816$
- Namun saat divisualisasikan:
  - **Dataset 1:** Pola linier terdistribusi rata
  - **Dataset 2:** Pola kurva kuadratik (non-linier)
  - **Dataset 3:** Garis lurus dengan 1 pencilan
  - **Dataset 4:** Titik bertumpuk dengan 1 outlier ekstrem

Datasaurus Dozen (2017):

- 13 dataset dengan mean, varians, dan korelasi yang sama persis hingga 2 angka desimal.
- Bentuk visualnya sangat bervariasi: **lingkaran, bintang, gelombang, hingga siluet dinosaurus**!

> **Pelajaran Kunci:**
> Ringkasan angka dapat menyembunyikan anomali besar. **Selalu visualisasikan data** sebelum menarik kesimpulan atau membangun model.

Prinsip EDA pada Big Data

Masalah Umum

Menggambar jutaan titik data langsung ke browser akan:

- Membuat notebook lambat atau macet
- Menghasilkan grafik yang padat dan sulit dibaca (*overplotting*)
- Menyita memori secara tidak perlu

Tiga Prinsip Utama

1. **Agregasi dulu** di database (SQL/DuckDB), baru bawa hasil kecil ke visualisasi
2. **Sampling** untuk scatter plot per baris (misal 20.000 dari 1 juta baris)
3. **Profiling ringkas** (`describe()`, cek null) sebelum membuat grafik

> Big data + EDA = kurangi volume data **sebelum** divisualisasikan, bukan sesudahnya.

Pipeline DuckDB → Polars → Plotly

```
import duckdb, polars as pl, plotly.express as px

con = duckdb.connect()
con.register("transaksi", df)  # DataFrame Polars langsung di-query

# 1. Agregasi di DuckDB — hanya hasil kecil yang dibawa ke tahap berikutnya
ringkasan = con.execute("""
    SELECT kota, SUM(harga * kuantitas) AS total_pendapatan
    FROM transaksi
    WHERE status = 'selesai'
    GROUP BY kota
    ORDER BY total_pendapatan DESC
""").pl()

# 2. Visualisasi hasil yang sudah ringkas
px.bar(ringkasan.to_pandas(), x="kota", y="total_pendapatan").show()
```

> Urutan yang efisien: **Query & Agregasi di DuckDB → hasil kecil ke Polars/Pandas → Render Plotly**.

Grammar of Graphics dengan Altair

Altair adalah library visualisasi deklaratif untuk Python berbasis **Vega** dan **Vega-Lite**.

Imperatif vs Deklaratif:

- **Imperatif (Matplotlib):**
  Mengatur langkah prosedural: *"buat canvas, gambar batang di koordinat (x,y), atur warna merah, atur label sumbu"*.
- **Deklaratif (Altair):**
  Menyatakan makna data: *"petakan kolom 'harga' ke sumbu Y dan 'kategori' ke warna batang"*.

3 Pilar Utama di Altair:

1. **Data:** DataFrame tabular (`alt.Chart(df)`)
2. **Mark:** Geometri visual (`.mark_bar()`, `.mark_point()`, `.mark_line()`, `.mark_circle()`)
3. **Encoding:** Menghubungkan variabel kolom ke atribut visual (`.encode(x=..., y=..., color=...)`)

> **Kaitan Khusus dengan Big Data:** Altair memiliki proteksi `MaxRowsError` (maks 5.000 baris) karena data disematkan ke spesifikasi JSON di browser. Ini memperkuat prinsip utama: **agregasi di DuckDB/Polars terlebih dahulu!**

Sistem Tipe Data Altair (Data Types)

Altair menggunakan anotasi tipe data untuk menentukan bagaimana skala sumbu, legenda, dan palet warna digambar secara otomatis.

Shorthand	Tipe Data	Karakteristik & Contoh	Representasi Visual
`:Q`	**Quantitative**	Numerik kontinu (harga, rating, pendapatan)	Sumbu linier kontinu, gradien warna
`:N`	**Nominal**	Kategori tanpa urutan (kota, kategori produk)	Sumbu diskrit, warna berbeda (*discrete palette*)
`:O`	**Ordinal**	Kategori berurutan (bintang 1-5, ukuran S/M/L)	Sumbu terurut, gradien bertingkat
`:T`	**Temporal**	Waktu dan tanggal (timestamp, bulan, tahun)	Sumbu waktu otomatis dengan format tanggal

```
chart = (
    alt.Chart(ringkasan.to_pandas())
    .mark_bar()
    .encode(
        x=alt.X("kota:N", sort="-y", title="Kota"),
        y=alt.Y("total_pendapatan:Q", title="Total Pendapatan (Rp)"),
        color=alt.Color("rata_rata_rating:Q", scale=alt.Scale(scheme="viridis")),
        tooltip=["kota:N", "total_pendapatan:Q", "rata_rata_rating:Q"],
    )
)
```

Komposisi & Interaktivitas Deklaratif Altair

Kekuatan utama Grammar of Graphics adalah kemudahan menyusun dashboard bertingkat (*composition*) dan menambahkan interaktivitas secara elegan.

Operator Komposisi Grafik:

- **Layering (`+`):** Menumpuk beberapa mark dalam satu chart (misal: bar penjualan + target garis).

```
chart_gabung = chart_bar + chart_garis
```

- **Horizontal (`|`):** Menjajarkan 2 chart berdampingan.

```
chart_dashboard = chart_distribusi | chart_tren
```

- **Vertical (`&`):** Menyusun chart atas dan bawah.

Interaktivitas Deklaratif:

- **Pan & Zoom:** Cukup tambahkan satu method:

```
chart.interactive()
```

- **Linked Brushing (Selection):**

```
brush = alt.selection_interval()
c1 = chart_scatter.add_params(brush)
c2 = chart_bar.transform_filter(brush)
# Seleksi di c1 otomatis memfilter data c2!
c1 | c2
```

> Altair mengubah visualisasi interaktif dari ratusan baris kode JavaScript menjadi beberapa baris spesifikasi deklaratif yang ringkas dan ekspresif.

Distribusi dan Deteksi Outlier

Box plot dan histogram jauh lebih informatif dibanding pie chart untuk melihat sebaran data numerik dan mendeteksi pencilan (*outliers*).

Box Plot (Distribusi per Kategori)

```
px.box(
    df_sampel,
    x="kategori",
    y="harga",
    points="outliers",
    title="Distribusi Harga per Kategori",
)
```

Histogram (Bentuk Sebaran Data)

```
px.histogram(
    df_sampel,
    x="rating",
    nbins=20,
    title="Distribusi Rating Transaksi",
)
```

> **Tips Praktis:** Gunakan data hasil **sampling** (misal 20.000 baris) agar visualisasi box plot dan histogram dapat di-render dengan cepat di browser tanpa mengorbankan representasi sebaran data.

Korelasi Antarvariabel Numerik

Heatmap korelasi membantu mengidentifikasi hubungan linier antarfitur numerik sebelum masuk ke tahap pemodelan machine learning.

```
# Hitung matriks korelasi dengan Polars
korelasi = df.select(["harga", "kuantitas", "rating"]).corr()

# Tampilkan dengan Plotly Express
fig_heatmap = px.imshow(
    korelasi.to_numpy(),
    x=korelasi.columns,
    y=korelasi.columns,
    text_auto=".2f",
    color_continuous_scale="RdBu_r",
    zmin=-1,
    zmax=1,
    title="Heatmap Korelasi Variabel Numerik",
)
fig_heatmap.show()
```

> Nilai mendekati **+1** menandakan korelasi positif kuat, **-1** korelasi negatif kuat, dan **0** tidak ada hubungan linier. Ingat: *korelasi bukan berarti sebab-akibat (causation)*!

Komposisi, Tren, dan Peta Interaktif

Bar Chart vs Pie Chart

Bar chart lebih mudah dibaca untuk banyak kategori — manusia lebih akurat membandingkan panjang batang daripada sudut irisan pie.

```
px.bar(komposisi, x="kategori", y="jumlah")
```

Peta Interaktif (scatter_geo)

```
px.scatter_geo(
    ringkasan_peta,
    lat="lat", lon="lon",
    size="total_pendapatan",
    color="rata_rata_rating",
    hover_name="kota",
    scope="asia",
)
```

Tren Waktu

```
px.line(tren_bulanan, x="bulan", y="total_pendapatan", markers=True)
```

Visualisasi yang Menyesatkan

Memotong sumbu Y (truncated axis) membesar-besarkan perbedaan kecil sehingga menyesatkan interpretasi.

```
# Benar: sumbu Y mulai dari 0
fig = px.bar(data, x="kategori", y="jumlah")
fig.update_yaxes(range=[0, data["jumlah"].max() * 1.1])

# Menyesatkan: sumbu Y dipotong, perbedaan terlihat ekstrem
fig2 = px.bar(data, x="kategori", y="jumlah")
fig2.update_yaxes(range=[data["jumlah"].min() * 0.95, data["jumlah"].max() * 1.01])
```

> Pola melengkung non-linier pada scatter plot? Coba **transformasi logaritma** (`pl.col("harga").log10()`) sebelum menyimpulkan tidak ada hubungan.

Ringkasan Pertemuan 5

Hari ini kita telah mempelajari:

- **Prinsip EDA big data**: agregasi/sampling dulu, baru visualisasikan
- **Pipeline** DuckDB (agregasi) → Polars (transform) → Plotly/Altair (visualisasi)
- **Grammar of Graphics**: pemetaan deklaratif data ke elemen visual
- **Pemilihan chart**: box plot/histogram (distribusi), heatmap (korelasi), bar chart (komposisi), line chart (tren), scatter geo (peta)
- **Visualisasi menyesatkan** (truncated axis) dan transformasi log untuk pola non-linier

Check-in Milestone 2 Tugas 1: DuckDB `SUMMARIZE` + transformasi Polars untuk cleaning, missing values, outliers, dan validasi dasar.

Pertemuan Berikutnya: Pemrosesan Data Time Series Besar — Resampling, Rolling Windows, `group_by_dynamic()`.

Referensi

- Plotly Express Documentation: https://plotly.com/python/plotly-express/
- Altair Documentation: https://altair-viz.github.io/
- Few, Stephen. *Now You See It: Simple Visualization Techniques for Quantitative Analysis*.